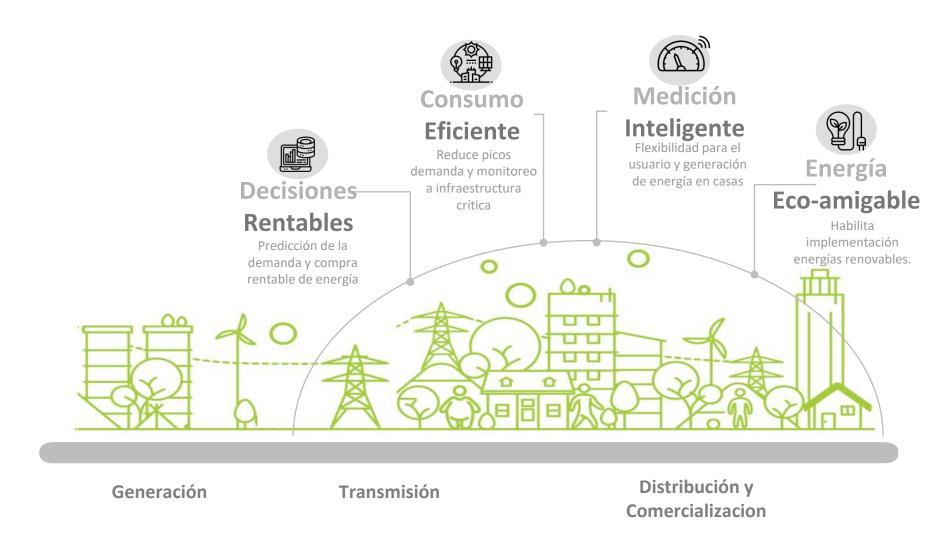
¿Cuál es el camino para lograr un sistema energético confiable, eficiente, amigable con el medio ambiente y rentable para empresas/usuarios: Smart-grids?

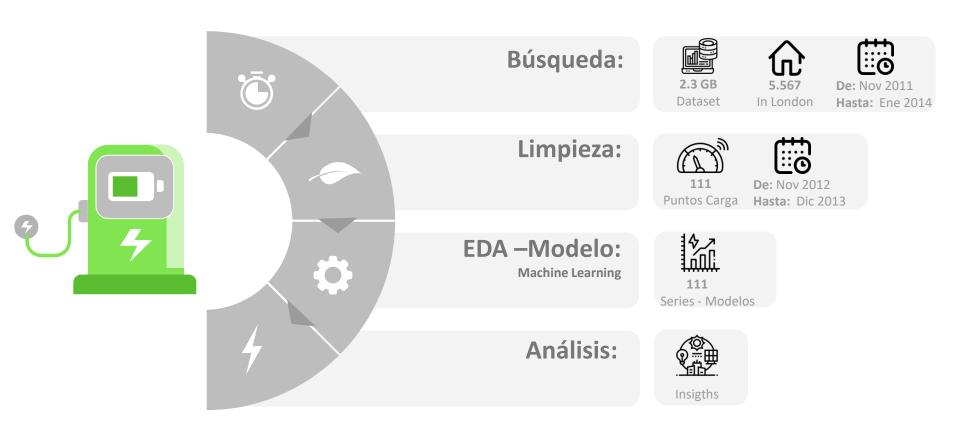
Presentado por: Cristhian M. Ordoñez



1. Generación de Valor para la Cadena Energética.



2. Caso Kaggle Área Londres



3. Expectativas

Rango Tiempo Óptimo

Identificar el **mejor** momento para realizar el análisis.

Consumo Energía Total

Evidenciar **consumo real** de acuerdo a Data.

Proyección Demanda

Proyección de Consumo por ciudad y bloques.



Tendencias Consumo

Identificar picos de demanda e **implicaciones** para el sistema.

Temporadas Consumo

Identificar **patrones de demanda** según temporadas climáticas.

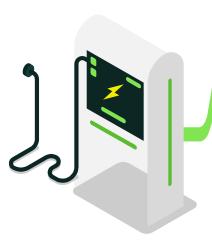
Infraestructura Critica

Identificar infraestructura crítica del sistema,

3.1 Principales Hallazgos

Rango Tiempo Óptimo

Identificar el mejor momento para realizar el análisis.



Implementación de Medidores Inteligentes en Londres



Hecho Clave:

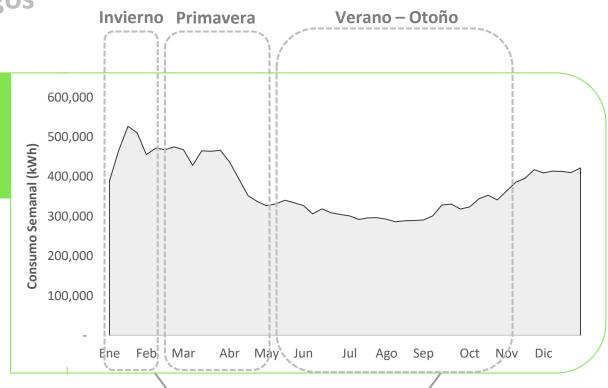
 La lenta implementación de medidores permeó la posibilidad de capturar mayor información homogénea de la muestras.

3.1 Principales Hallazgos

Tendencias Consumo

Identificar picos de demanda e implicaciones para el sistema.





Hecho Clave:

 Controlar y realizar una mejor estimación de comportamiento/patrones de la demanda permite capturar un mayor poder de negociación para la compra de energía y en la identificación de fuentes de generación que suplan la demanda.

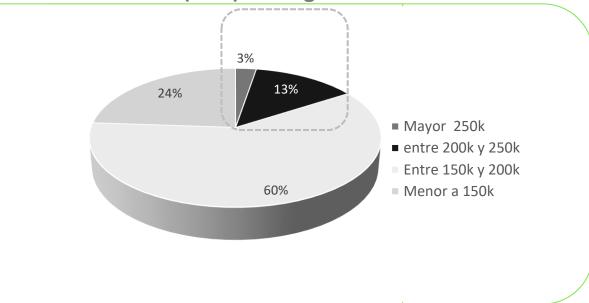
3.1 Principales Hallazgos

Infraestructura Critica

Identificar infraestructura crítica del sistema,



Consumo Total (kwh) – Riesgo de Falla



Hechos Claves:

- 18 Bloques de Carga concentran una carga de energía superior a los 200.000 kwh por año, que implican un mantenimiento más costoso y aumentan el riesgo de caída del sistema.
- "Por cada hora que no tienen suministro de electricidad, las firmas del sector pierden 200 millones de dólares."

1. Noticia Diario la Jornada por apagones en el norte de México.

3.2 Elección del Modelo – AutoRegresión

Proyección Demanda

Proyección de Consumo por ciudad y bloques.



Consumo Energía Total Bloque



Hechos Clave:

- La prueba de hipótesis confirmó comportamiento NO estacionario.
- Los datos poseen dependencia de tipo no lineal, que los modelos de regresión tradicionales (AR | Holts Winter | Propteht) no son capaces de capturar impidiendo realizar proyección realista.

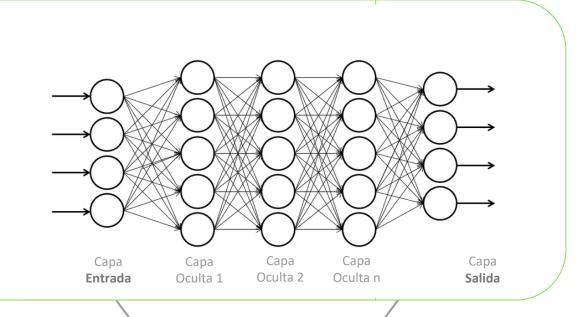
3.3 Elección del Modelo – Redes Neuronales Profundas

Proyección Demanda

Proyección de Consumo por ciudad y bloques.



Ejemplo Red Neuronal



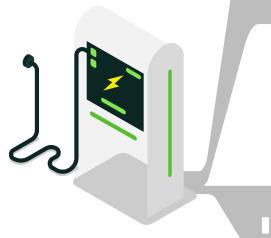
Hechos Clave:

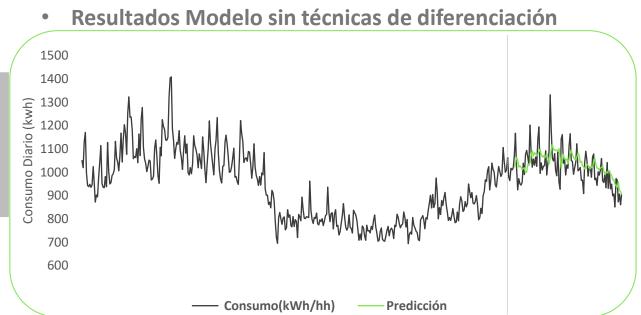
- Son un conjunto de neuronas conectadas entre sí y que trabajan en conjunto para resolver un problema.
- Recibe un conjunto de entradas, permitiendo que cada "aprenda" a encontrar y detectar las características que mejor ayudan a clasificar los datos.

3.3 Modelo Machine Learning – Redes Neuronales Profundas

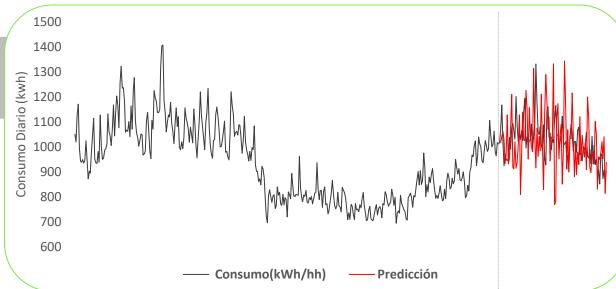
Proyección Demanda

Proyección de Consumo por ciudad y bloques.





Resultados Modelo con técnicas de diferenciación



4. Conclusiones



Modelo

Los modelos de redes neuronales profundas permiten tener una proyección más adecuada de la demanda de energía.

Datos

A pesar de ser un Dataset robusto, solo cuenta con información valiosa de un año, lo cual permea la posibilidad de tener mejores resultados de proyección.

Caso Real

Después de este estudio, el gobierno de Reino Unido decidió iniciar la implementación total de esta tecnología.

Expectativas

Se cumple con el objetivo de identificar patrones y tendencias de consumo, identificación de infraestructura critica y la necesidad de implementación de este tipo de tecnologías.

Gracias



Credits: This presentation template was created by

Slidesgo, incluiding icons by **Flaticon**. Please keep this slide for **attribution**.